

Trabajo 1

Estudiantes

Juan Manuel Saldarriaga Velasquez
Manuela Ospina Usma
Juan Pablo Vanegas Moreno
Kilmer Alejandro Peña Jiménez
Equipo 33

Docente

Veronica Guarín

Asignatura

Estadística II



UNIVERSIDAD
NACIONAL
DE COLOMBIA

Sede Medellín
13 de octubre de 2022

Índice

1. Pregunta 1	3
1.1. Modelo de regresión	3
1.2. Significancia de la regresión	3
1.3. Significancia de los parámetros	4
1.4. Interpretación de los parámetros	4
1.5. Coeficiente de determinación múltiple R^2	4
2. Pregunta 2	4
2.1. Planteamiento prueba de hipotesis y modelo reducido	4
2.2. Estadístico de prueba y conclusiones	5
3. Pregunta 3	5
3.1. Prueba de Hipótesis y Prueba de Hipótesis Matricial	5
3.2. Estadístico de Prueba	5
4. Pregunta 4	6
4.1. Supuestos del modelo	6
4.1.1. Normalidad de los residuales	6
4.2. Media 0 y Varianza constante	7
4.2.1. Datos atípicos	7
4.2.2. Puntos de balanceo	8
4.2.3. Puntos influenciados	8

Índice de figuras

1.	Gráfico de residuales estudentizados vs Valores ajustados	7
2.	Identificación de datos atípicos	7
3.	Identificación de puntos de balanceo	8
4.	Criterio de distancias de Cook para puntos influenciados	8
5.	Criterio Dffits para puntos influenciados	9

Índice de tablas

1.	Tabla de valores de los coeficientes estimados	3
2.	Tabla anova significancia de la regresión	3
3.	Resumen de los coeficientes	4
4.	Resumen de todas las regresiones	5

1. Pregunta 1

Teniendo en cuenta la base de datos asignada, la cual es **Equipo33.txt**, las covariables son: conteo de células rojas (RCC), Conteo de células blancas (WCC), Hematocritos (Hc), Masa corporal libre de grasa (LBM), Estatura en cms (Ht), Peso en kgs(Wt), El modelo que se propone es:

$$X.Bfat_i = \beta_0 + \beta_1 RCC + \beta_2 WCC + \beta_3 Hc + \beta_4 LBM + \beta_5 Ht + \beta_6 Wt + \varepsilon_i, \quad \varepsilon_i \stackrel{iid}{\sim} \mathcal{N}(0, \sigma^2)$$

1.1. Modelo de regresión

Al ajustar el modelo de regresión, se obtienen los siguientes coeficientes:

Tabla 1: Tabla de valores de los coeficientes estimados

	Valor del parámetro
$\hat{\beta}_0$	9.7968
$\hat{\beta}_1$	-0.6514
$\hat{\beta}_2$	0.0518
$\hat{\beta}_3$	0.0394
$\hat{\beta}_4$	-1.3539
$\hat{\beta}_5$	0.0384
$\hat{\beta}_6$	1.1371

Por lo tanto, el modelo de regresión ajustado es:

$$\widehat{X.Bfat_i} = 9.7968 + -0.6514RCC_i + 0.0518WCC_i + 0.0394Hc_i + -1.3539LBM_i + 0.0384Ht_i + 1.1371Wt_i$$

Donde $1 \leq i \leq 75$

1.2. Significancia de la regresión

Para la significancia de la regresión se hará uso de la siguiente tabla anova:

Tabla 2: Tabla anova significancia de la regresión

	Sumas de cuadrados	g.l	Cuadrado medio	F_0	Valor-P
Modelo de regresión	2209.5822	6	368.263706	646.513	6.55552e-58
Error	38.7338	68	0.569615		

Como el $ValorP < 0.05 = \alpha$ se rechaza la hipótesis nula concluyendo que el modelo de RLM propuesto es significativo, por consiguiente el porcentaje de grasa corporal depende significativamente de al menos una de las variables predictoras del modelo.

1.3. Significancia de los parámetros

En el siguiente cuadro se presenta información de los parámetros con la cual se va a estimar si los parámetros son significativos en el modelo o no:

Tabla 3: Resumen de los coeficientes

	Estimación β_j	$se(\hat{\beta}_j)$	T_{0j}	Valor-P
β_0	9.7968	2.4959	3.9252	0.0002
β_1	-0.6514	0.5831	-1.1171	0.2679
β_2	0.0518	0.0654	0.7921	0.4311
β_3	0.0394	0.0742	0.5319	0.5965
β_4	-1.3539	0.0364	-37.2427	0.0000
β_5	0.0384	0.0151	2.5357	0.0135
β_6	1.1371	0.0225	50.5356	0.0000

los valores P permiten concluir con una significancia $\alpha = 0.05$ que $\hat{\beta}_4$, $\hat{\beta}_5$ y $\hat{\beta}_6$ son significativos en el modelo y que $\hat{\beta}_1$, $\hat{\beta}_2$ y $\hat{\beta}_3$ son individualmente no significativos en presencia de los demás parámetros.

1.4. Interpretación de los parámetros

- $\hat{\beta}_4$: Masa corporal libre de grasa $\hat{\beta}_4 = -1.3539$ indica que por cada unidad que aumente la masa corporal libre de grasa, el promedio de porcentaje de grasa corporal va a disminuir en 1.3539 unidades.
- $\hat{\beta}_5$: Estatura en cm $\hat{\beta}_5 = 0.0384$ indica que por cada unidad que aumente la estatura(cm), el promedio de porcentaje de grasa corporal va a aumentar en 0.0384 unidades.
- $\hat{\beta}_6$: Peso en cm $\hat{\beta}_6 = 1.1371$ indica que por cada unidad que aumente el peso(kg), el promedio de porcentaje de grasa corporal va a aumentar en 1.1371 unidades.

1.5. Coeficiente de determinación múltiple R^2

El modelo tiene un $R^2 = 0.9828$ lo cual significa que aproximadamente el 98.28% de la variabilidad es explicado por el modelo sin embargo el $R^2_{adj} = 0.9813$ se puede ver como el $R^2_{adj} < R^2$ lo que indica que el en el modelo pueden haber variables que no aporten significativamente.

2. Pregunta 2

2.1. Planteamiento prueba de hipótesis y modelo reducido

Los parámetros cuyos valores P fueron los mas altos corresponden a $\beta_1, \beta_2, \beta_3$. Por tanto, se plantea la siguiente prueba de hipótesis:

$$\begin{cases} H_0 : \beta_1 = \beta_2 = \beta_3 = 0 \\ H_1 : \text{Algún } \beta_j \text{ distinto de } 0 \text{ para } j = 1, 2, 3 \end{cases}$$

El modelo completo es el definido en la sección 1.1 y el modelo reducido es:

$$\text{MR: } X.Bfat_i = \beta_0 + \beta_4 LBM + \beta_5 Ht + \beta_6 Wt + \varepsilon_i, \quad \varepsilon_i \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2)$$

Se presenta la siguiente tabla con el resumen de todas las regresiones para plantear el estadístico de prueba:

Tabla 4: Resumen de todas las regresiones

	SSE	Covariables en el modelo					
Modelo completo	38.734	RCC	WCC	Hc	LBM	Ht	Wt
Modelo reducido	39.990				LBM	Ht	Wt

2.2. Estadístico de prueba y conclusiones

Se construye el estadístico de prueba como:

$$\begin{aligned}
 F_0 &= \frac{(SSE(\beta_0, \beta_4, \beta_5, \beta_6) - SSE(\beta_0, \beta_1, \dots, \beta_6))/3}{MSE(\beta_0, \beta_1, \dots, \beta_6)} \stackrel{H_0}{\sim} f_{3,68} \\
 &= \frac{(39.990 - 38.734)/3}{38.734/68} = 0.735
 \end{aligned}$$

Ahora, comparando a un nivel de significancia F_0 con $f_{3,68} = 2.7395023$

Viendo el resultado anterior se concluye que las variables $\beta_0, \beta_4, \beta_5, \beta_6$ se pueden retirar del modelo.

3. Pregunta 3

3.1. Prueba de Hipótesis y Prueba de Hipótesis Matricial

Se quiere saber si el efecto de WCC es igual a la resta del efecto de Hc y RCC; además de analizar si LBM y Wt tienen el mismo efecto en el análisis actual. Para ello se plantea la siguiente prueba de hipótesis:

$$\begin{cases} H_0 : \beta_2 = \beta_3 - \beta_1, \beta_4 = \beta_6 \\ H_a : \text{Alguna desigualdad no se cumple.} \end{cases}$$

Reescribiendo matricialmente se obtiene:

$$\begin{cases} H_0 : \mathbf{L}\underline{\beta} = 0 \\ H_a : \mathbf{L}\underline{\beta} \neq 0 \end{cases}$$

Donde $\mathbf{L}$ esta dada por:

$$\mathbf{L} = \begin{bmatrix} 0 & 1 & 1 & -1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & -1 \end{bmatrix}$$

Por lo anterior, el modelo reducido se puede expresar como:

$$\begin{aligned}
 X.Bfat_i &= \beta_0 + \beta_1 RCC + (\beta_3 - \beta_1)WCC + \beta_3 Hc + \beta_4 LBM + \beta_5 Ht + (\beta_4)Wt + \varepsilon_i, \quad \varepsilon_i \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2) \\
 &= \beta_0 + \beta_1(RCC - WCC) + \beta_3(WCC + Hc) + \beta_4(LBM + Wt) + \beta_5 Ht + \varepsilon_i, \quad \varepsilon_i \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2) \\
 &= \beta_0 + \beta_1(RCC^*) + \beta_3(WCC^*) + \beta_4(LBM^*) + \beta_5 Ht + \varepsilon_i, \quad \varepsilon_i \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2)
 \end{aligned}$$

3.2. Estadístico de Prueba

El estadístico de prueba F_0 esta dado por:

$$F_0 = \frac{(SSE(MR) - SSE(MF))/2}{MSE(MF)} \stackrel{H_0}{\sim} f_{2,68} \quad (1)$$

4. Pregunta 4


4.1. Supuestos del modelo

4.1.1. Normalidad de los residuales

Para la validación de este supuesto, se plantea la sigui prueba de hipotesis Shpiro wilk, acompañado de un grafico cuantil-cuantil:

Se plantea la siguiente prueba de hipotesis:

$$\begin{cases} H_0 : \varepsilon_i \sim N(0, \sigma^2) \\ H_1 : \varepsilon_i \not\sim N(0, \sigma^2) \end{cases}$$



Dado el gráfico qqnorm y la prueba de Shaphiro Wilk con el juego de hipótesis ya nombrado, se observa que el valor p es de 0.000554 (grande) por tanto se rechaza la hipótesis nula y se concluye que los residuales NO distribuyen normal estándar.

Note que hay un buen ajuste de los datos a excepción de los primeros 6 puntos iniciales. Es probable que estos datos son los que están afectando la normalidad en gran medida. Ahora, en términos prácticos, la desviación no parece muy fuerte. A pesar de que el supuesto no se cumple se ha de mencionar que la desviación de la normalidad no es tan grave. Esto es destacable dado que, es posible que con una transformación de los datos, el modelo resultante cumpla ahora el supuesto de normalidad.

4.2. Media 0 y Varianza constante




Figura 1: Gráfico de residuales estudentizados vs Valores ajustados

Analizando el gráfico anterior podemos concluir que el modelo planteado cumple con el supuesto de media 0 y varianza constante.

Notemos que hay algunos puntos que se encuentran dispersos, pero en general podemos concluir lo propuesto anteriormente.

4.2.1. Datos atípicos




Figura 2: Identificación de datos atípicos

Observando el gráfico vemos que es un dato atípico, esta observación es la número 59, la cual tiene un $|r_{estud}| > 3$, el resto de observación se encuentran dentro de los límites.

4.2.2. Puntos de balanceo




Figura 3: Identificación de puntos de balanceo

Al realizar un análisis del gráfico anterior, y con base en el criterio de los h_{ii} que es $h_{ii} > 2p/n$, se pueden detectar 4 puntos de balanceo para este modelo los cuales son los que se encuentran en la parte superior de la línea roja. Estas son las observaciones 4, 25, 50 y 59.

4.2.3. Puntos influenciados

Bajo el criterio de Cook, el cual nos dice que si $D_i > 1$ la observación i , será influenciada tenemos:




Figura 4: Criterio de distancias de Cook para puntos influenciados

Según la gráfica basada en la distancia de Cook, nos damos cuenta que no existe una observación con D_i alto, es decir que no hay ninguna observación que tenga influencia sobre el vector de parámetros estimados $\hat{\beta}$.

Bajo el criterio de DFFITS, el cual nos dice que una observación sera influyente si $|DFFITS_i| > 2\sqrt{p/n}$, asi:




Figura 5: Criterio Dffits para puntos influyentes

Según la gráfica basada en el diagnóstico DFFITS, existen seis observaciones las cuales son mayores al criterio, es decir, $|DFFITS_i| > 2\sqrt{p/n}$, lo que las hace influyentes. Dichas observaciones son la 4, 15, 16, 29, 50 y 59.